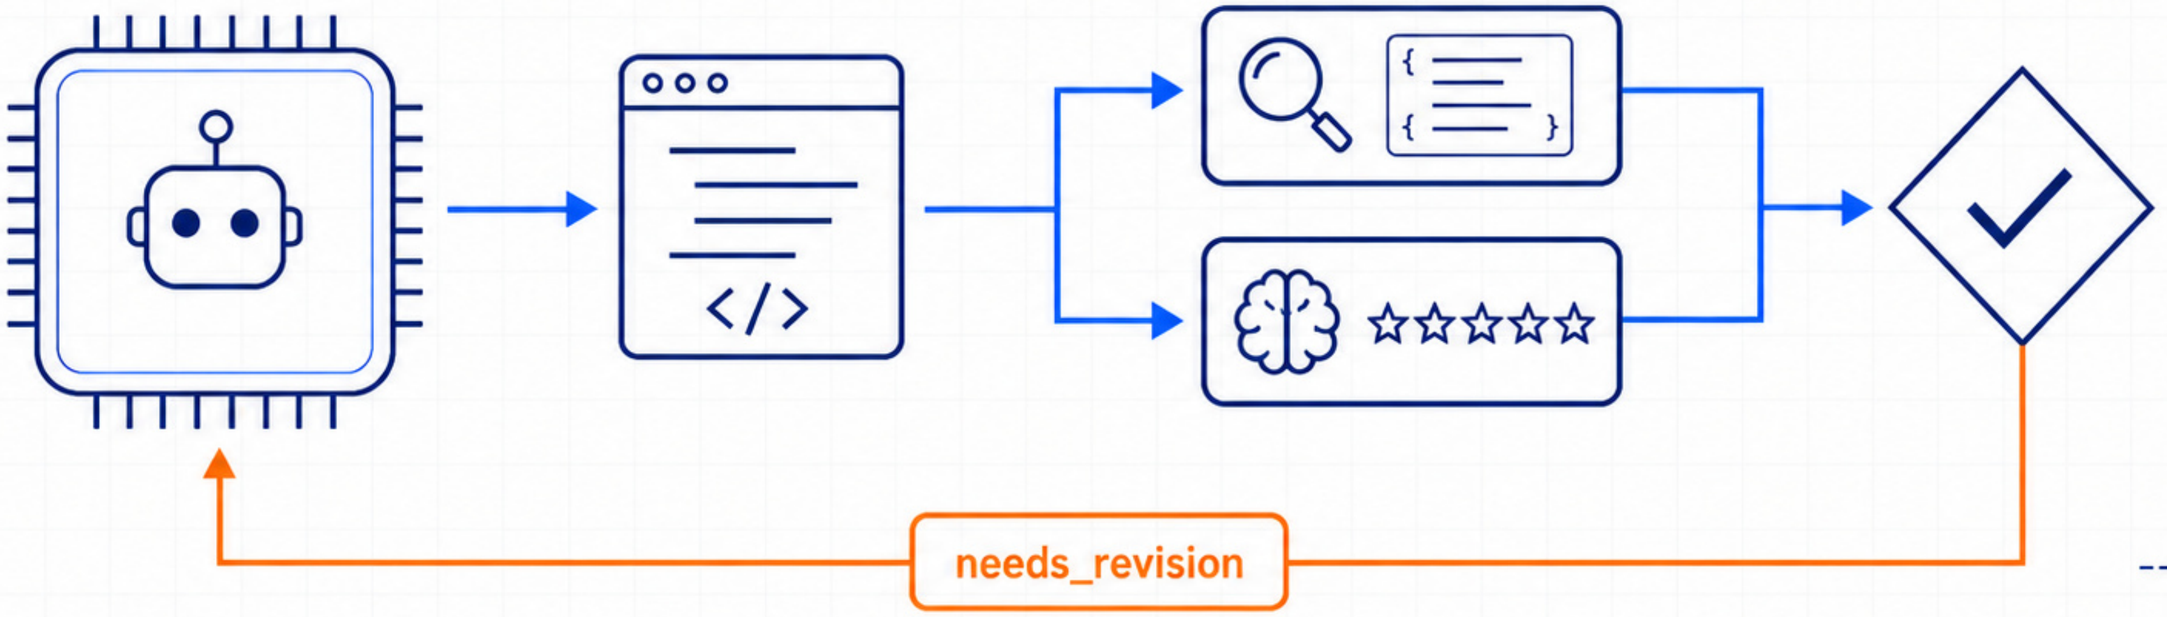
Deep Agents 实战

第 13 章：评分量规

让 Agent 按验收标准自我迭代



生成结束，不等于通过验收

一个完整答案，仍可能在边界输入上失败

常规输入

`find_duplicates([1, 2, 2, 3, 1]) → [2, 1]`

边界输入

`find_duplicates([[1], [1]]) → TypeError`

Prompt（提示词）
声明要求

Self-Check（自检）
再次判断

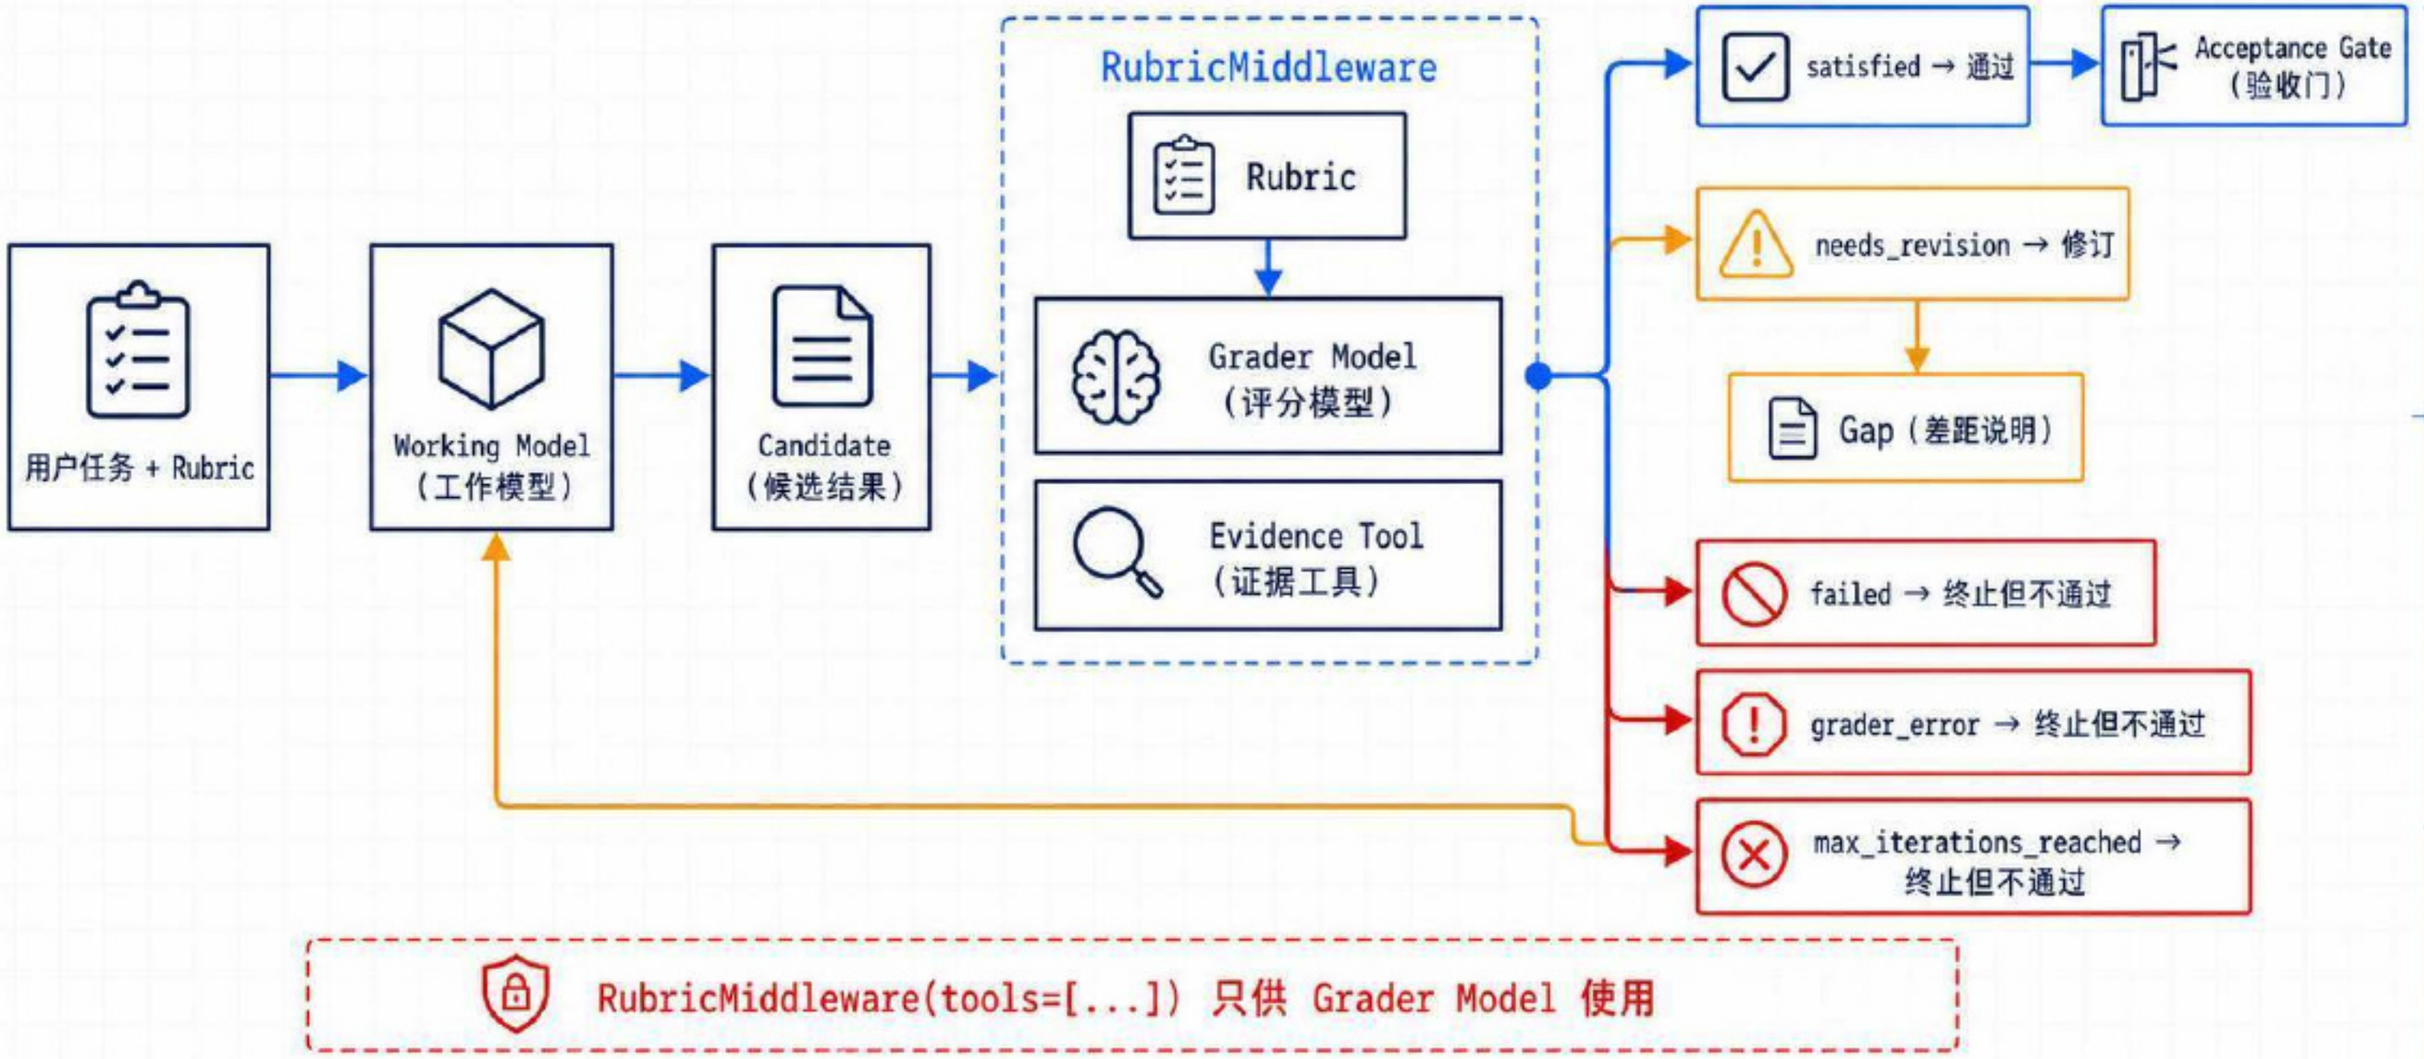
Retry（重试）
再次生成

- 仍缺少
- 独立评审
- 工具证据
- 可执行 Gap
- 失败关闭

生成结束 ≠ 验收通过

Rubric Middleware 在自然停止后接管验收

只有 needs_revision 会回环，只有 satisfied 可以放行



固定版本，分开工作模型与评分模型

RubricMiddleware 是 Beta API；升级后必须重跑回归实验

安装

```
uv add "deepagents==0.7.15" langchain-openai
```

Working Model：生成与修订候选

Grader Model：依据标准与证据形成结论

验收门

接受

拒绝

两个角色可以使用相同模型，也可以分别配置

环境变量：WORKING_MODEL / GRADER_MODEL → 格式：provider:model-id

最低需要 deepagents >= 0.6.5

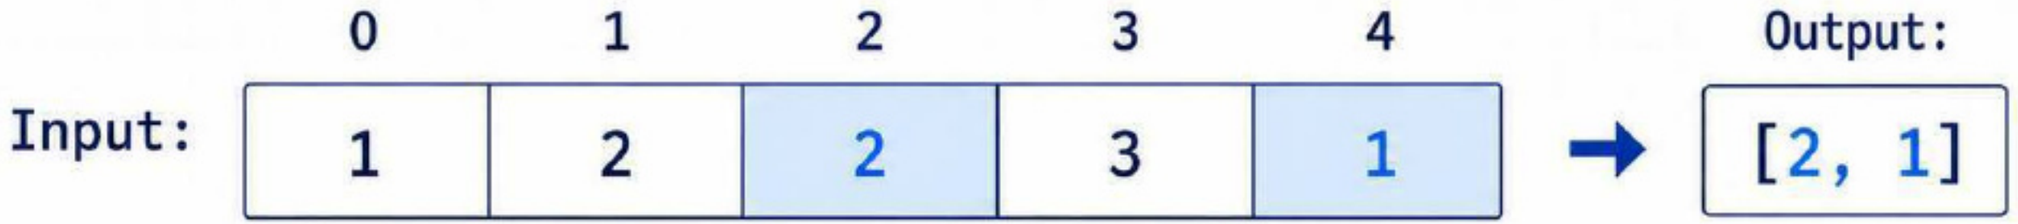
评分模型需支持结构化输出与工具调用

两个模型不构成正确性保证，确定性事实仍需测试

先固定 find_duplicates 的任务契约

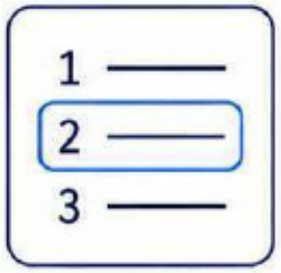
Task、测试和 Rubric 必须使用同一种排序语义

`find_duplicates(values)`

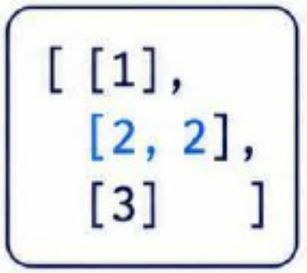




每个重复值只返回一次



按第二次出现的位置排序



支持列表等不可哈希值



不修改输入列表

把完成条件写成可取证的 Rubric

通过前必须测试最新候选，而且测试结果必须 ok=true

```
rubric = """
  - Before returning satisfied, call run_test_suite
    with the latest candidate code.
  - The run_test_suite result must contain ok=true.
  - Each duplicated value appears exactly once.
  - Result order follows the second appearance.
  - Unhashable values are supported.
  - The input list is not mutated.
""".strip()
```



Evidence Tool：先产生可检查的事实

教学测试工具接收候选源码，返回结构化测试结果

候选源码 → 加载 find_duplicates → 四组行为测试 → 结构化结果

test_basic	检查返回值	检查输入未修改
test_empty	检查返回值	检查输入未修改
test_no_duplicates	检查返回值	检查输入未修改
test_unhashable	检查返回值	检查输入未修改

```
{"ok": false, "failures":
["test_unhashable: TypeError"]}
```

```
{"ok": true, "failures": []}
```

加载失败或缺少函数也返回 ok=false；完整教学实现见配套源码。

四组测试只是当前证据，不是全部输入上的正确性证明。

exec 与受限 builtins 都不是安全沙箱；生产环境必须隔离不可信代码，并限制资源、网络和执行时间。

不接模型，先证明测试工具能抓住错误

没有 API Key，也能先验证 Evidence Tool

```python
def find_duplicates(values):
    seen = set()
    duplicates = []
    for value in values:
        if (
            value in seen
            and value not in duplicates
        ):
            duplicates.append(value)
        seen.add(value)
    return duplicates
```

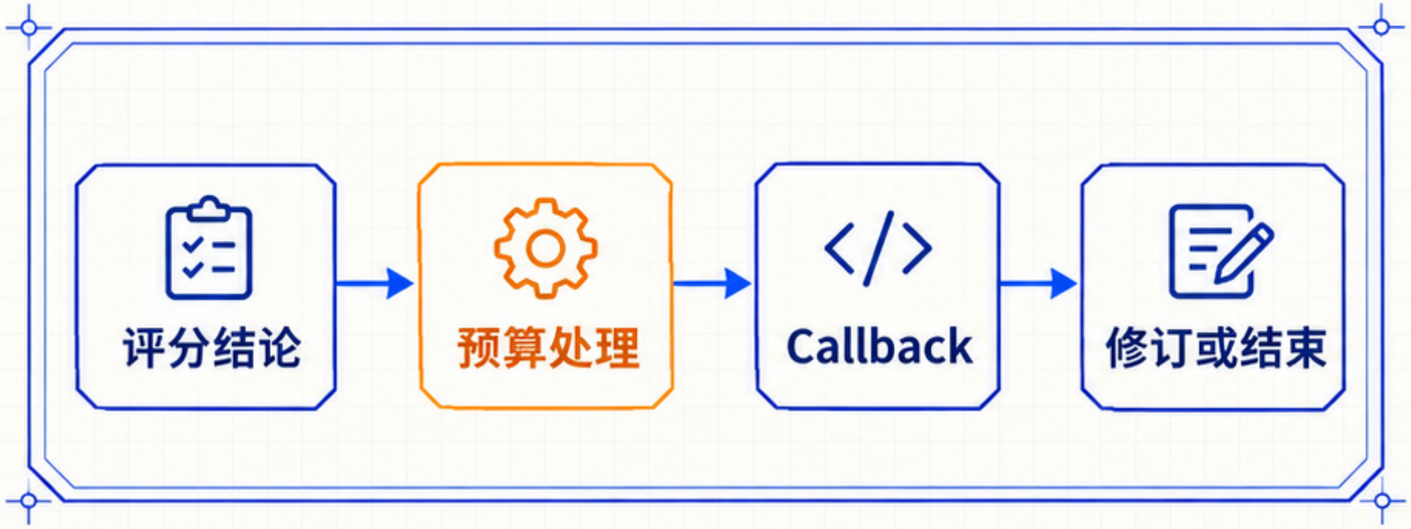
```
run_test_suite.invoke({"code": bad_candidate})
```

```
{
  'ok': False,
  "failures": [
    "test_unhashable: TypeError: unhashable type: 'list'"
  ]
}
```

失败已复现

on_evaluation 记录每轮结果，不控制放行

Callback 是观察入口，普通异常会被记录并抑制



grading_run_id：	一次评分尝试
iteration：	从 0 开始
result：	本轮结果
criteria：	逐项 passed 与 gap
unverified：	标准覆盖不足标记

预算耗尽时，Callback 看到 max_iterations_reached

同一 thread_id 可包含多次 grading_run_id

并发按运行归属保存；以 (grading_run_id, iteration) 做幂等键

不要用共享全局列表混合请求；

不要靠 Callback 抛异常阻止 Agent。

用五个参数构造 RubricMiddleware

只有 model 必填，其余四项按需覆盖默认行为

```
rubric_middleware = RubricMiddleware(
    model=grader_model,
    system_prompt=(
        "You are a strict code grader. "
        "Always obtain current test evidence."
    ),
    tools=[run_test_suite],
    max_iterations=3,
    on_evaluation=record_evaluation,
)
```

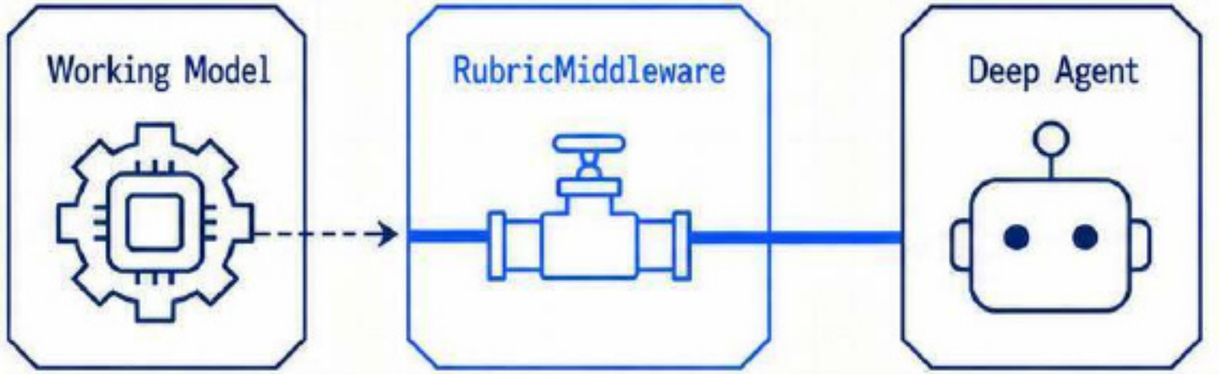
1. model：必填 · 谁来评分
2. system_prompt：可选 · 怎样评分
3. tools：可选 · 怎样取证
4. max_iterations：可选 · 默认 3
5. on_evaluation：可选 · 记录结论

⚠ tools=[run_test_suite] 只供 Grader Model 使用

把 Middleware 挂进 Agent 才会生效

创建实例还不够，真正的挂载点是 middleware=[rubric_middleware]

```
agent = create_deep_agent(
    model=working_model,
    system_prompt=(
        "Return only executable Python source. "
        "Revise when the grader reports a gap."
    ),
    middleware=[rubric_middleware],
    checkpointer=InMemorySaver(),
)
```

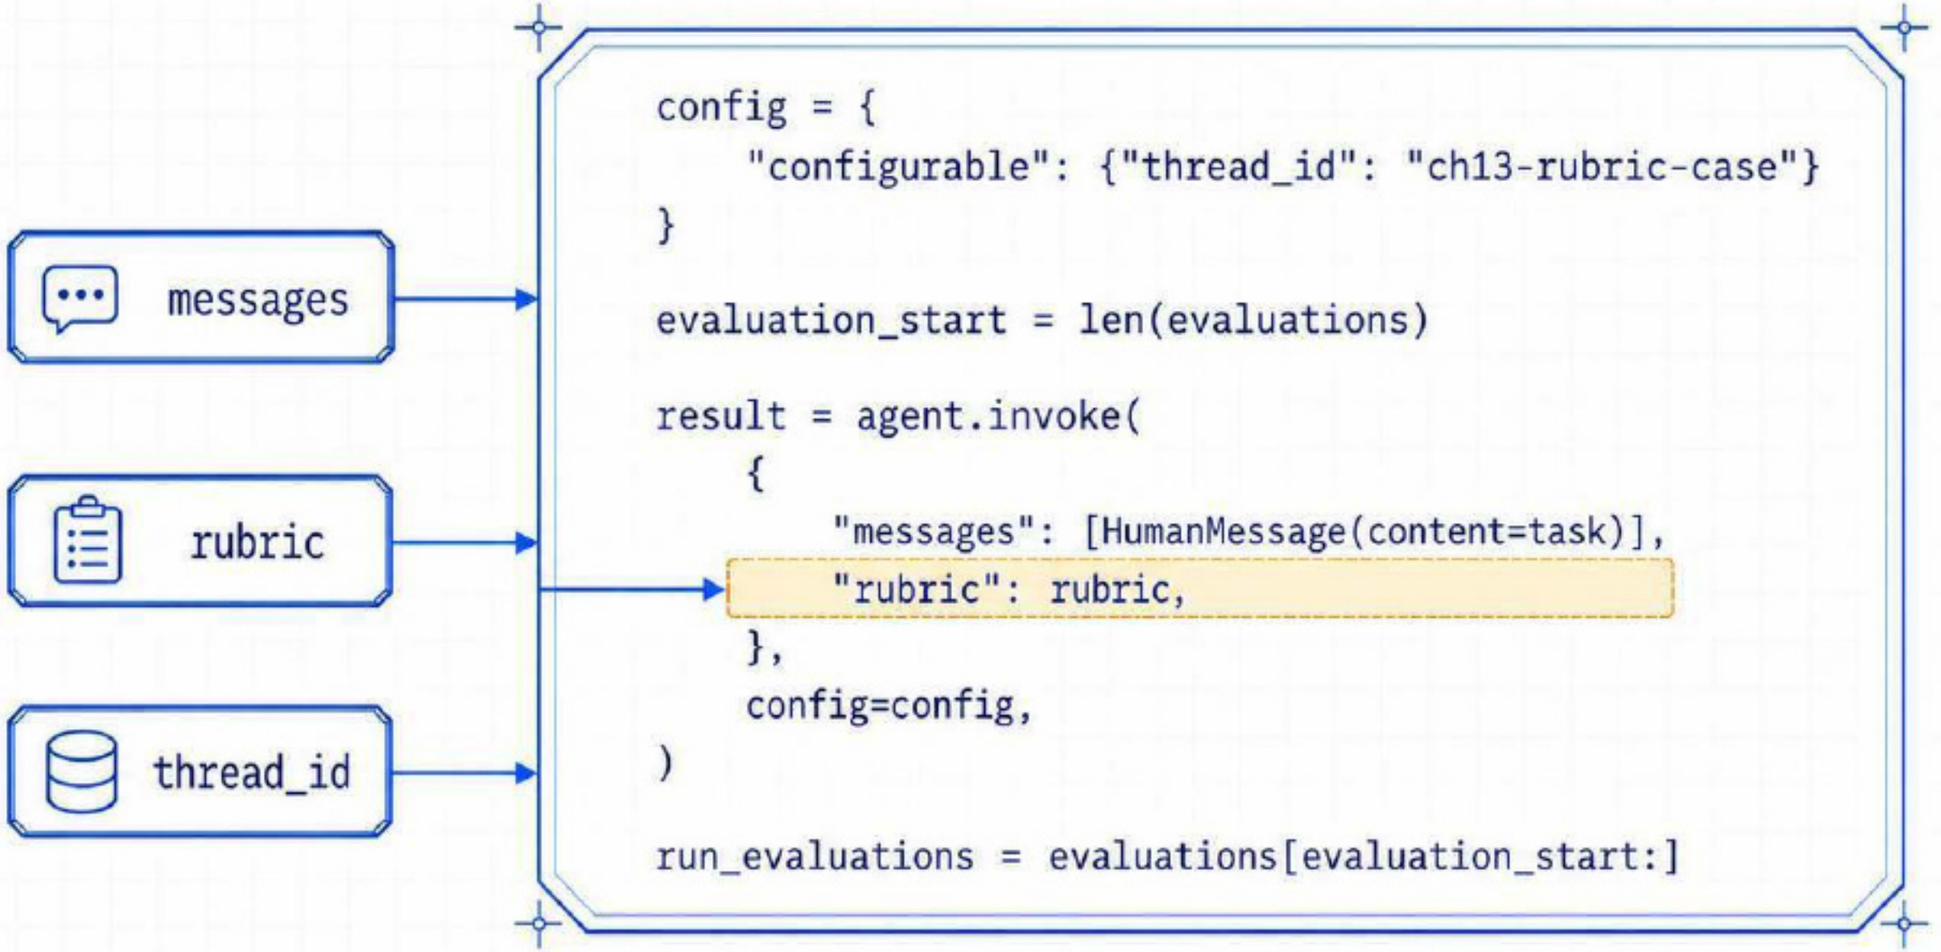


RubricMiddleware(tools=[...]) → Grader Model

create_deep_agent(tools=[...]) → Working Model

首次 invoke 显式传入 rubric，启动评分循环

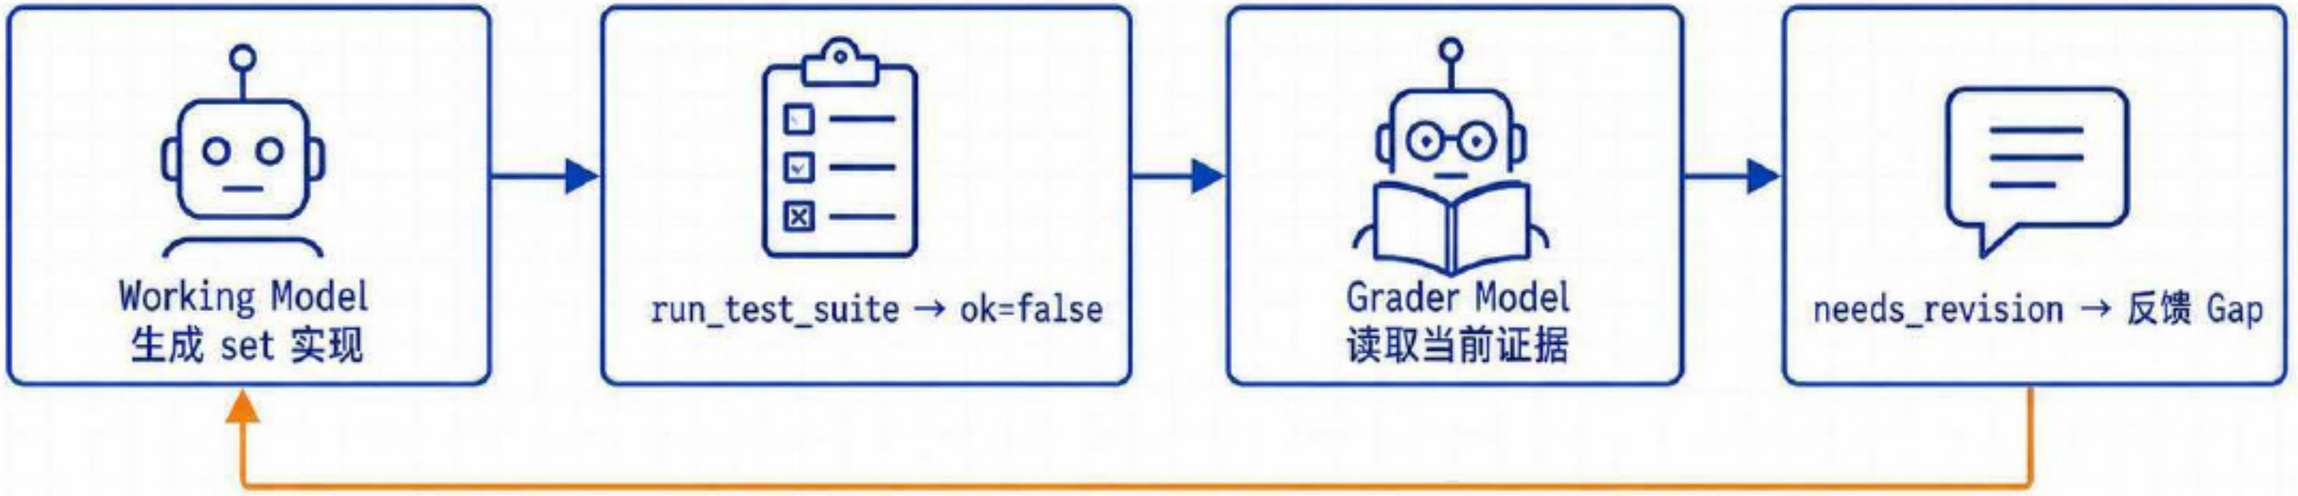
同一 thread_id 可延续已有 Rubric；新任务使用新的 thread_id



首次调用或新任务 → 显式传入非空 rubric

第一轮失败后，needs_revision 会触发修订

真正回到 Working Model 的是可执行 Gap



代表性运行

```
iteration 0: needs_revision
gap: Unhashable values are supported
      — test_unhashable raised TypeError
```

避免依赖 Hash，改用相等性比较

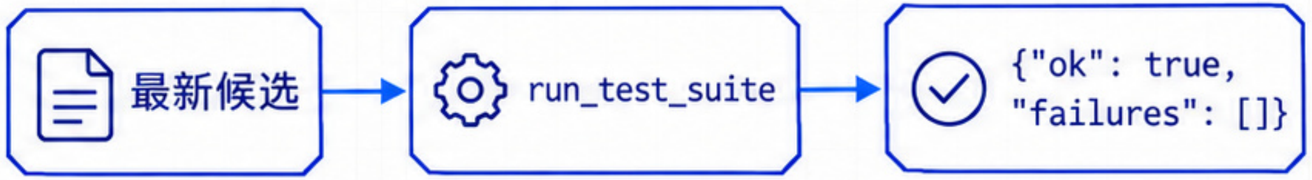
真实模型也可能第一轮直接通过

修订后重新取证：列表比较代替集合

每个重复值只返回一次，按第二次出现排序，不修改输入

```
def contains(items, target):
    return any(item == target for item in items)

def find_duplicates(values):
    seen = []
    duplicates = []
    for value in values:
        if (contains(seen, value) and
            not contains(duplicates, value)):
            duplicates.append(value)
        seen.append(value)
    return duplicates
```



支持列表等不可哈希值

去重检查不能省略

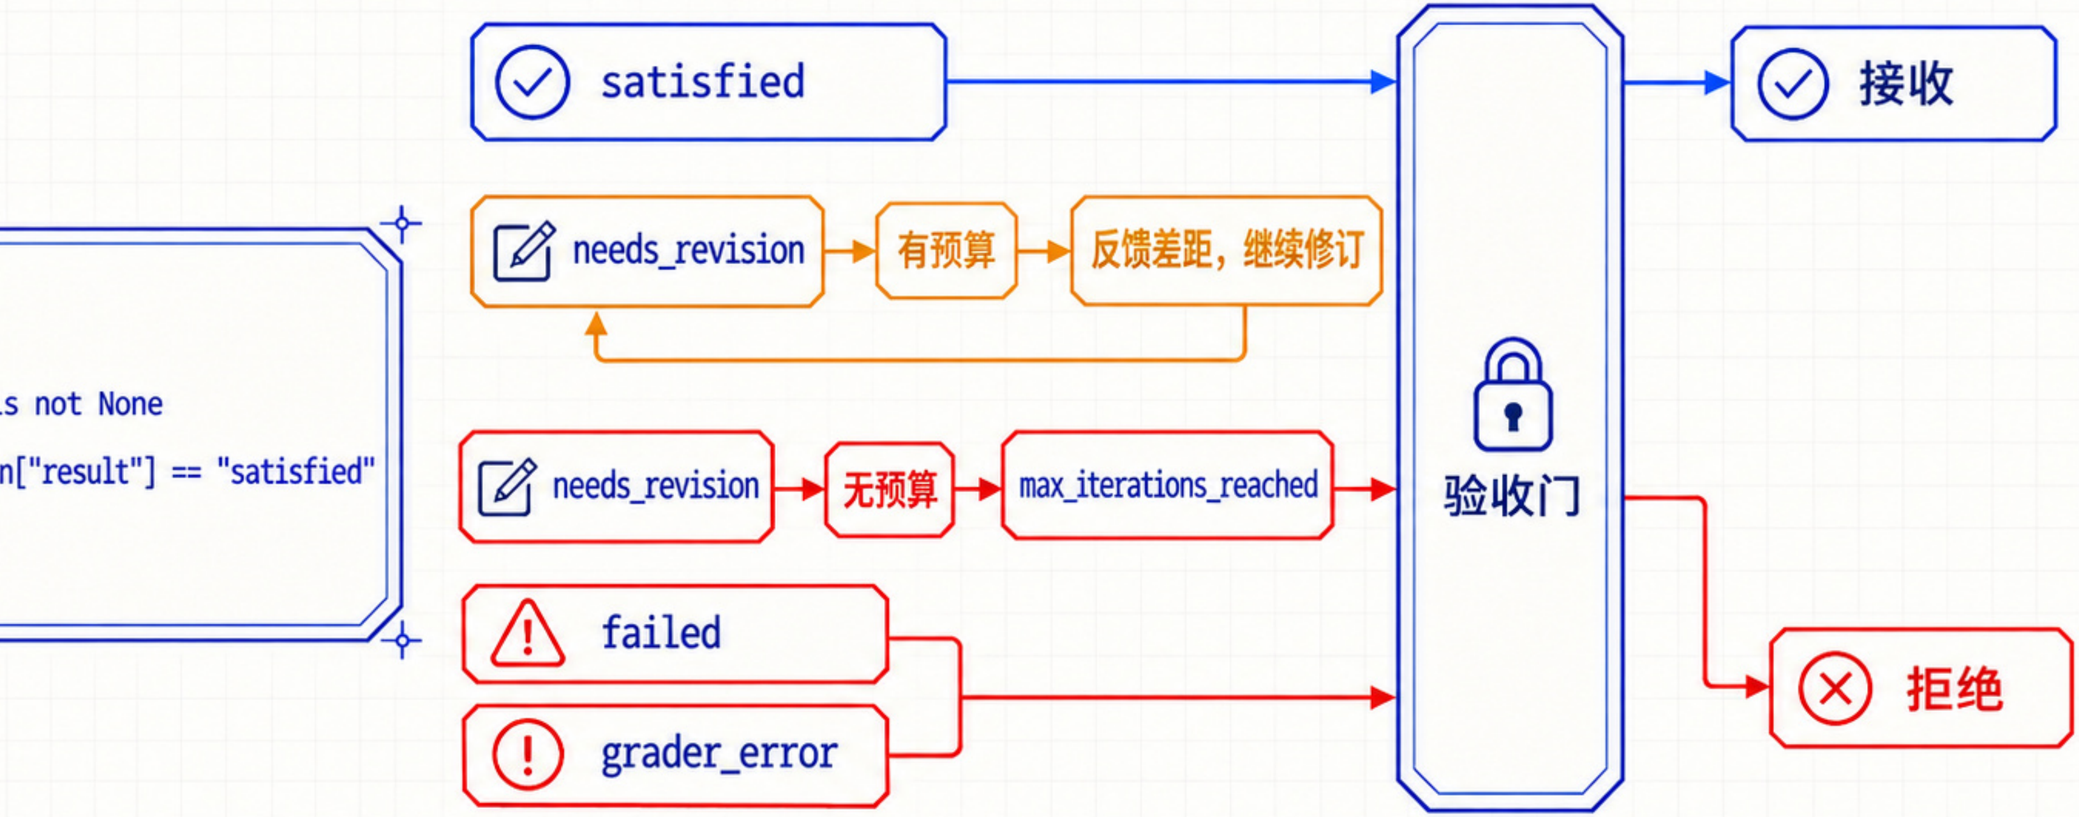
旧证据不能证明新候选

测试通过后仍由评分方形成结论；代表性结果为 satisfied，不承诺固定修订次数。

只有 satisfied 才放行，停止不等于通过

章节核对 deepagents 0.7.15；预算转换发生在 Callback 之前

```
accepted = (
    final_evaluation is not None
    and final_evaluation["result"] == "satisfied"
)
```



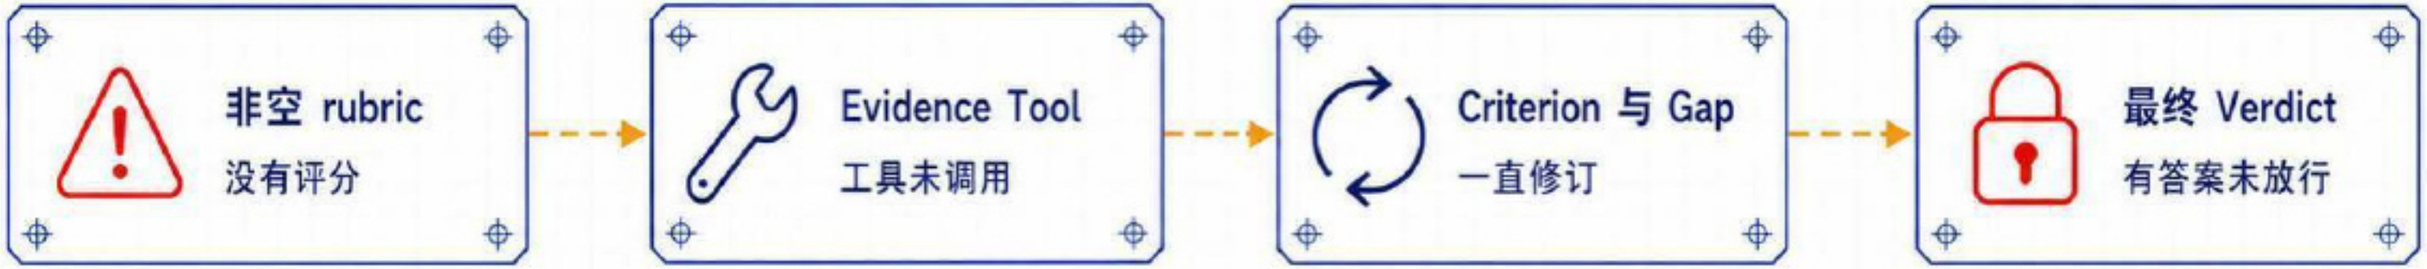
⚠ 最后一轮预算耗尽时，Callback 的 result 也是 max_iterations_reached。

ⓘ 缺少评审记录默认拒绝；有最终消息不是验收证据。

观察、状态延续与放行各有独立入口

Callback 看结果，事件流看进度，Checkpoint 续状态，验收门做决定





生产验收：证据、隔离、预算缺一不可

Rubric 改善当前运行，不替代安全控制和离线评测

证据可追溯

- 记录当前候选版本或内容摘要
- 测试证据绑定同一候选
- 保留 grading_run_id 与逐项结论

执行要隔离

- 文件、网络、凭据最小化
- 限制 CPU、内存与时间
- 不可信代码不在宿主进程执行

失败有去向

- 预算耗尽或评分异常不放行
- 转人工复核或标为未验收
- 统计首轮通过率、成本与人工推翻率

配套 Notebook 可先跑无模型实验；AgentSeek 仅作可选脚手架，模板能力需按版本重新核验。