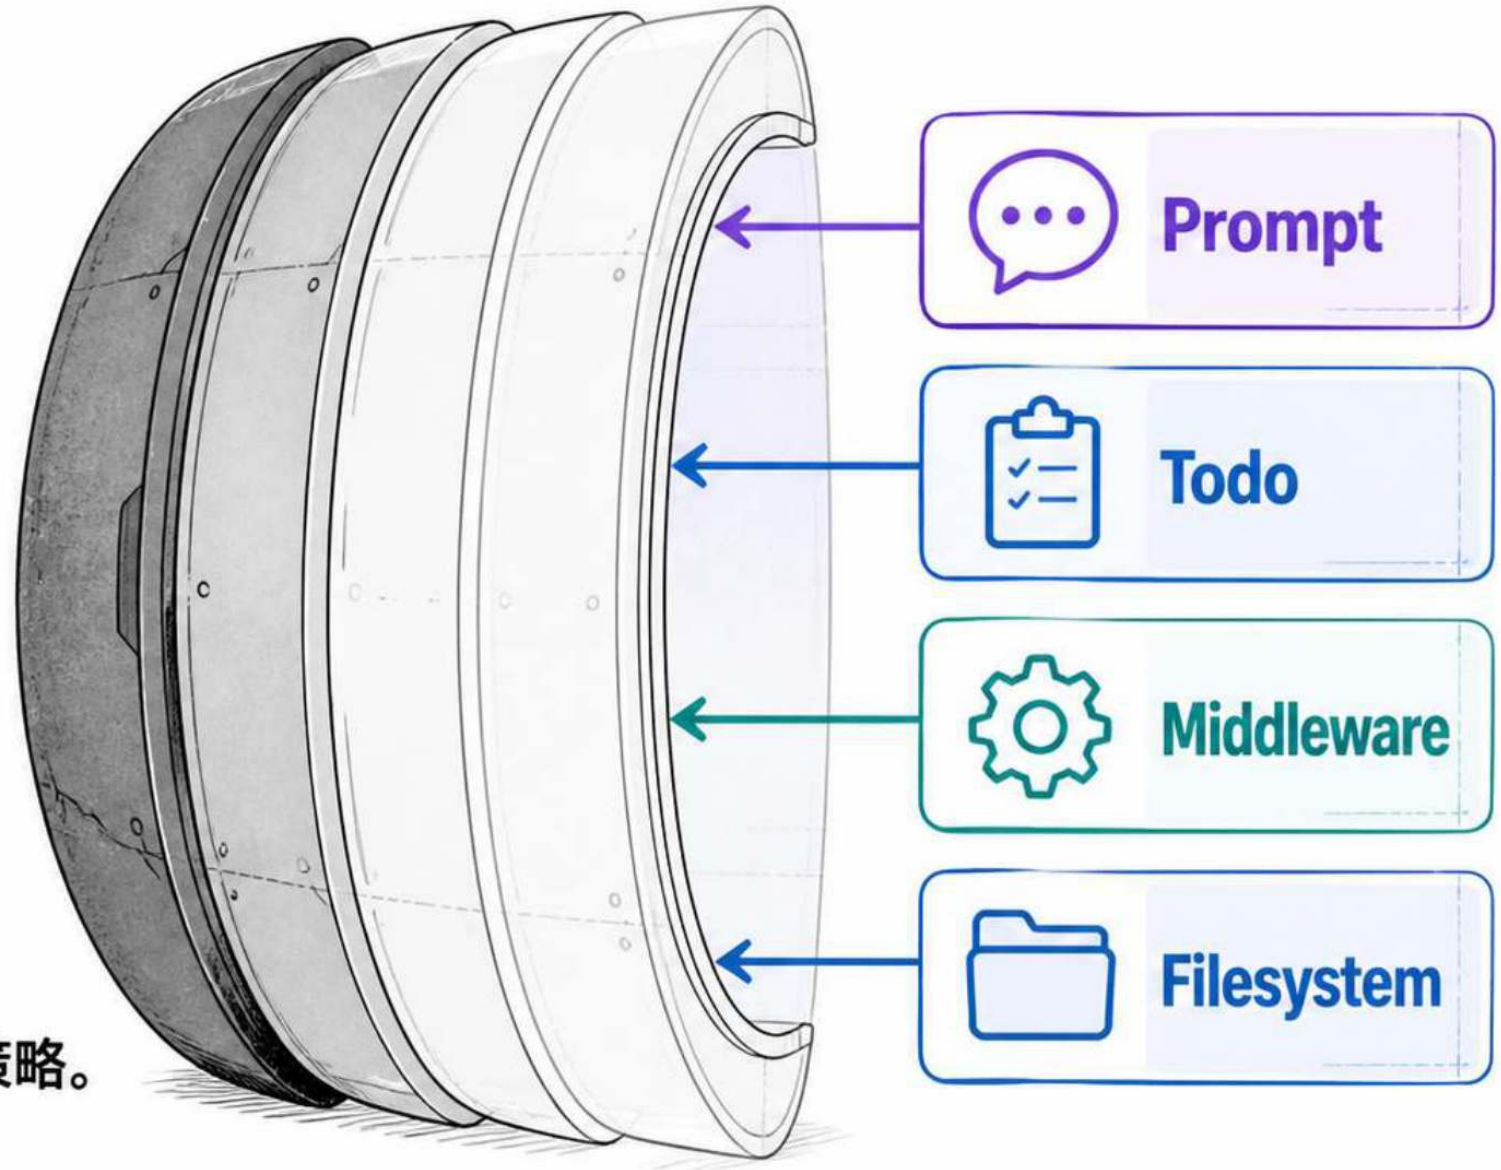
Deep Agents v0.7

更轻、更透明、更可配置的 Harness

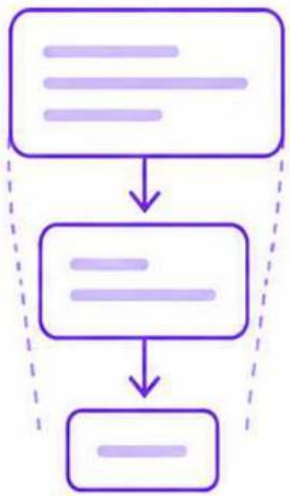
默认层变薄之后，应用必须主动选择策略。



先按 changelog 看全貌，再判断升级影响

1 组优化、4 组功能、3 组破坏性变化

Optimizations

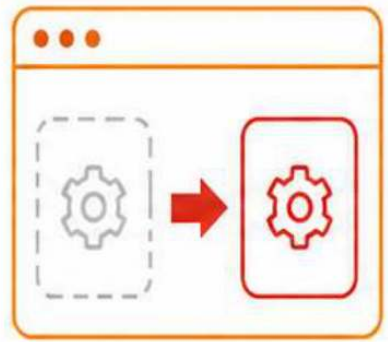


- 空基础 Prompt
- 精简工具描述
- 基础输入 -65%

Features

- Middleware 覆盖
- 文件工具
- Prompt Caching
- NVIDIA 支持

Breaking changes



- Todo 改为可选
- Backend 兼容层移除
- 输出格式变化

Source: Deep Agents v0.7.0 changelog

基础输入减少 65%，不等于总成本下降 65%

65%

Source: Deep Agents v0.7 blog / PR #5009

5,395 → 1,895 Token：默认简单回合基础输入

5,395 → 1,895

4,005 → 2,302 Token：工具描述，下降 43%

4,005 → 2,302 ↓43%

实际账单仍受历史、工具结果、子 Agent、摘要和重试影响

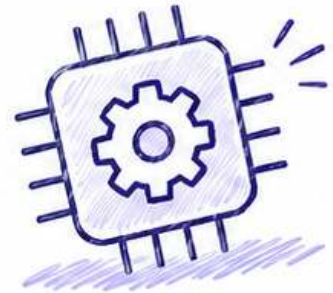


基础开销下降，不等于所有模型都更省

官方对照：v0.6.12 vs v0.7；36 个任务 × 3 次 rollout



模型	Reward变化	Token变化	成本变化
gpt-5.6-luna	+3.8%	−35.5%	−15.2%
gemini-3.6-flash	−6.7%	−4.7%	−8.1%
claude-sonnet-4-6	+3.1%	+31.3%	+36.8%
claude-opus-4-8	−5.1%	−25.4%	−16.4%







Reward：
全部置信区间跨零

Token：
Luna / Opus 降幅更明确

成本：
Luna 下降更明确，
Sonnet 轨迹更长

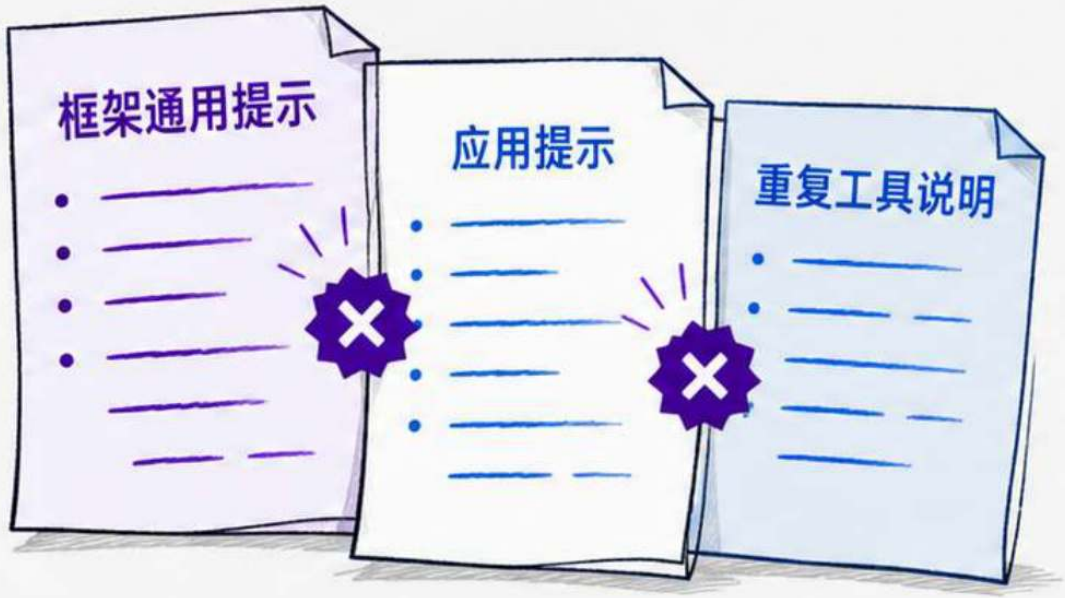
⚠ 未测到整体质量回退 ≠ 所有模型质量提升；用自己的任务验证。

Source: 章节 §2.1 / 官方 PR #5009

Prompt 变空，让业务指令真正“说了算”

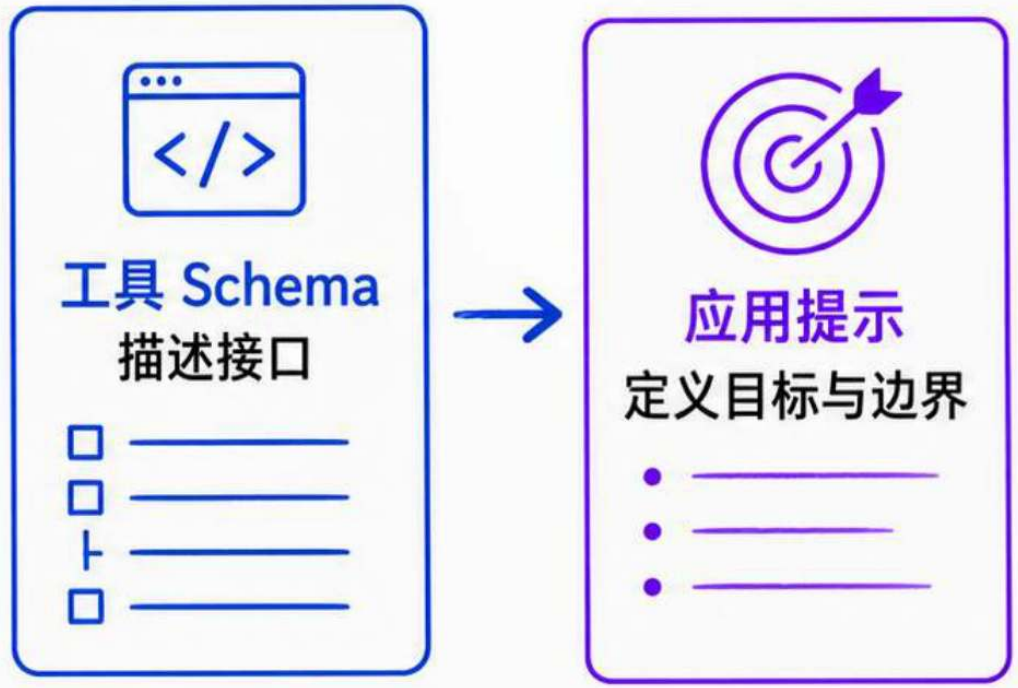
接口负责描述能力，系统提示词只保留业务约束。

旧： 框架通用提示 + 应用提示 + 重复工具说明



⚠ 不要为了怀旧把旧长 Prompt 整段复制回来

新： 工具 Schema 描述接口，应用提示定义目标与边界



Todo 从默认税费，变成任务策略

v0.7 默认不启用；按任务与产品需要显式恢复

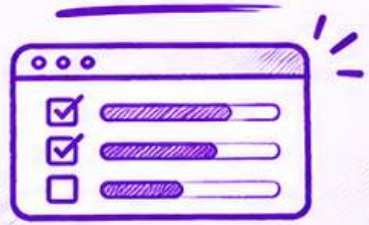
任务与产品需要
如何使用 Todo？

短任务 → Off

长程 / 弱模型 → A/B 后决定



UI 需要计划进度 → Enable



Todo 不会自动传给子 Agent

默认 general-purpose：
默认栈没有 Todo；
需同名 spec 显式启用

声明式子 Agent：
在自己的 middleware
中启用

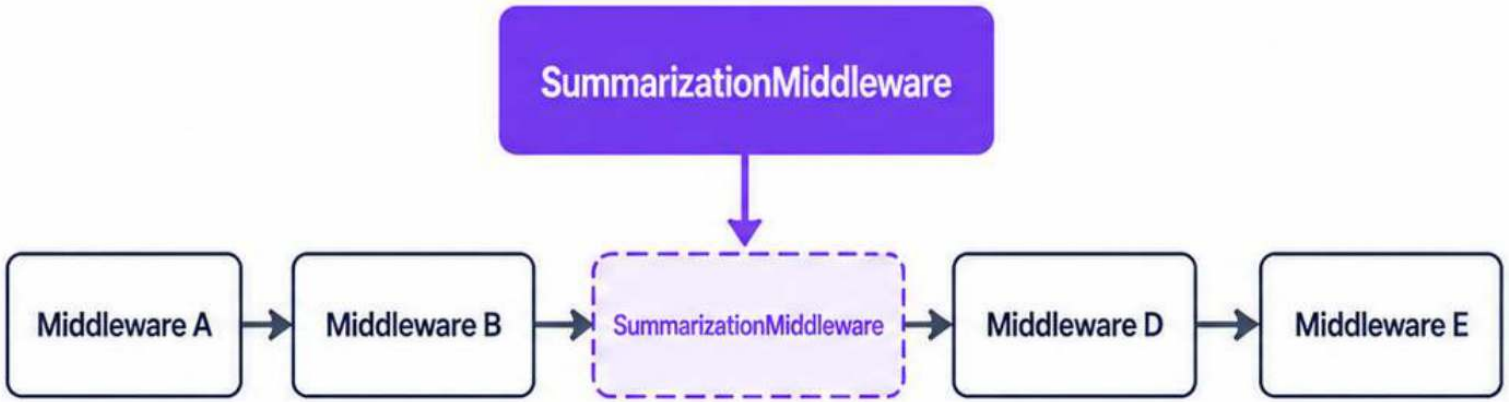
```python
from langchain.agents.middleware import TodoListMiddleware
agent = create_deep_agent(
    model=model, middleware=[TodoListMiddleware()]
)
```

示意片段：
create_deep_agent 与
model 需先导入 / 初始化。

默认隔离模式下各自维护 todos； Codex profile 是自动保留 Todo 的例外。

Middleware 可以替换，但不会帮你合并配置

同名实例在原位置换；替换的是完整对象，不是单个字段。



- 同名：保持栈顺序，原位替换
- 不同名：插入核心层之后、尾部能力之前
- Backend、阈值、提示词与权限状态都要重新审查
- 主 Agent 覆盖会影响默认 general-purpose 子 Agent

⚠ 替换 ≠ 合并

Backend　trigger　keep　summary_prompt

文件工具变强，边界必须写清

能力、默认值与直接 Backend API 不要混为一谈

1 delete



可删除文件 / 递归目录；审查权限与审批

⚠ 高风险删作用

2 write_file



目标存在时完整覆盖；局部修改用 edit_file

⚠ 先确认再写入

3 allowlist

收窄内置工具；read_file 必需；不能扩展 Backend 能力



🛡 收窄工具面

4 read_file



总行数、剩余行数、下一 offset；减少盲读

ⓘ 更丰富的分页信息

5 grep / glob



超时可返回有效部分结果；保留 truncated=True

ⓘ 大结果集更可控

6 grep 边界



Agent 工具默认 max_count=1000，可调整；直接 Backend 默认无上限

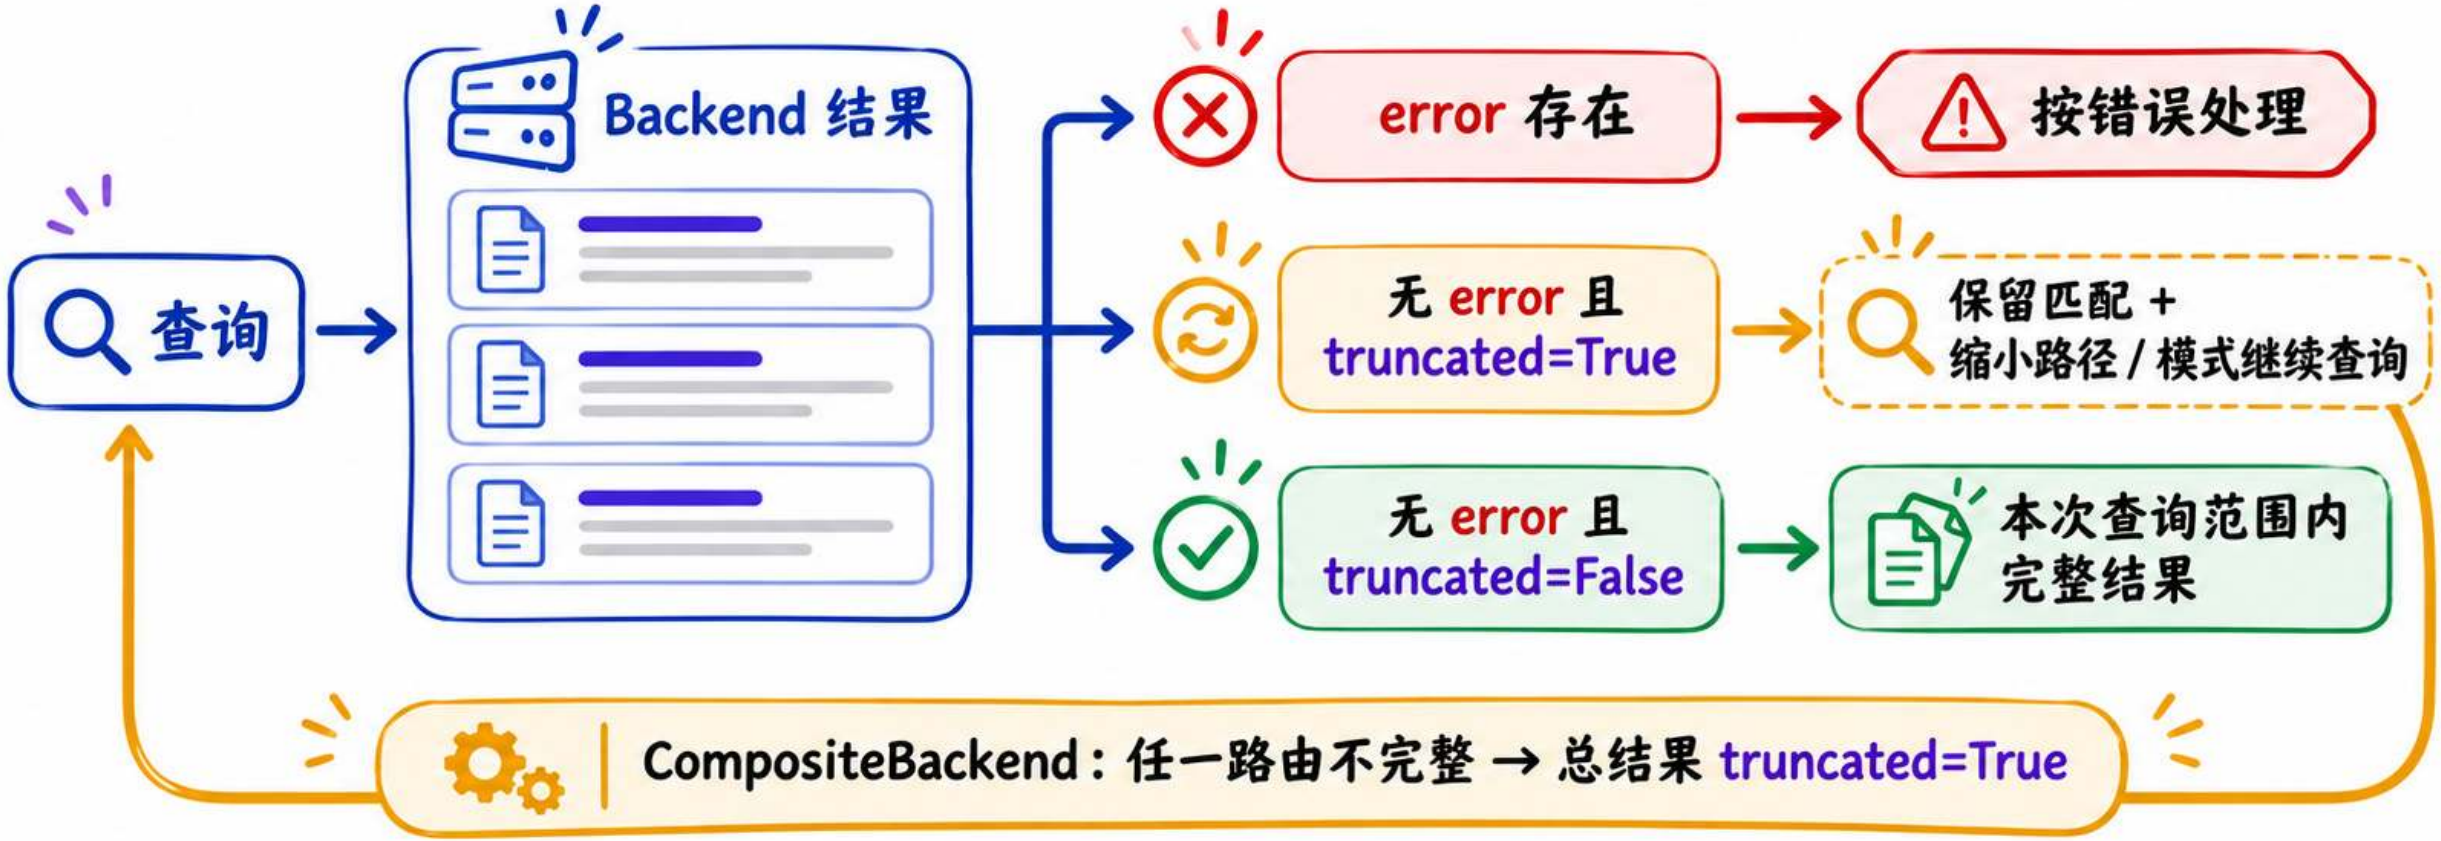
ⓘ 更快首屏与上下文

✎ **context_lines：v0.7.0 首先支持本地 FilesystemBackend.grep() 直接调用，不是通用 Agent 工具参数。**

Source: v0.7.0 首发基线；补丁差异需锁版本并回归。

没有报错，不代表搜索结果完整

有效匹配可以保留，但完整性必须单独判断

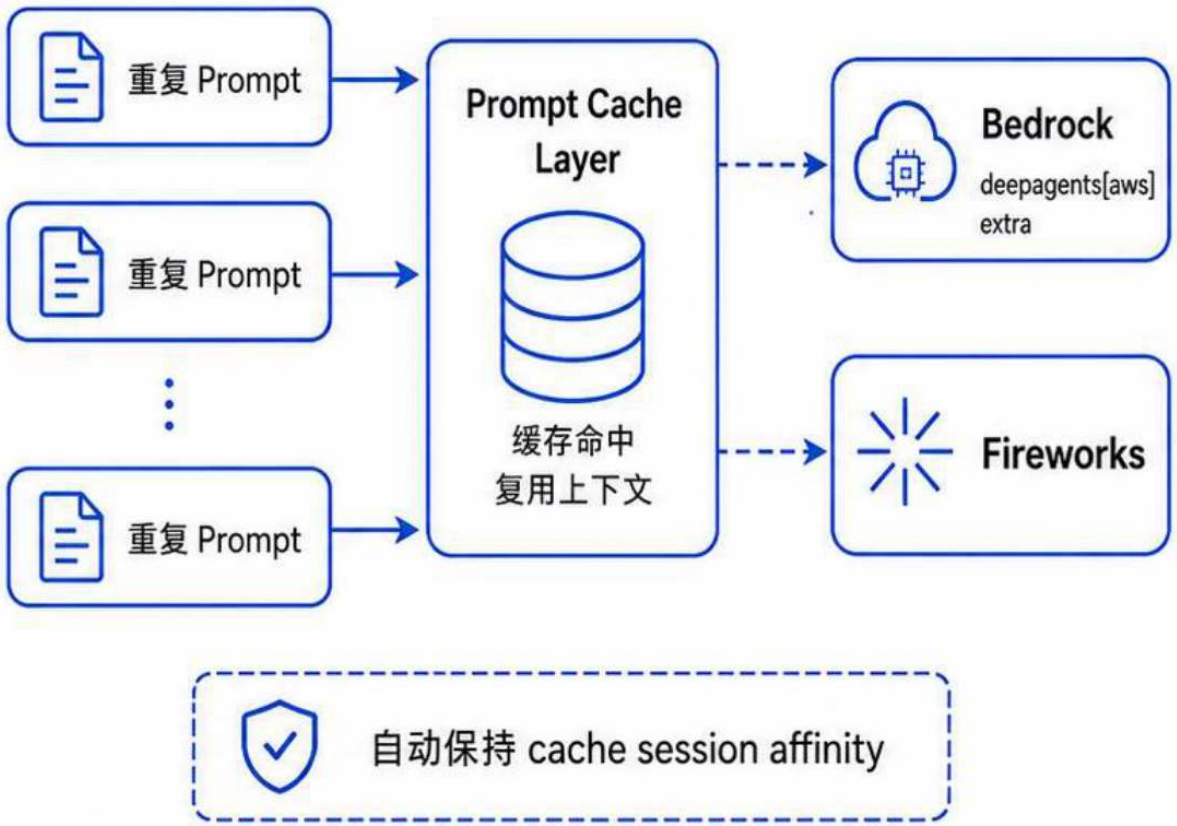


ToolMessage 成功只表示调用结果有效，不等于匹配全集。

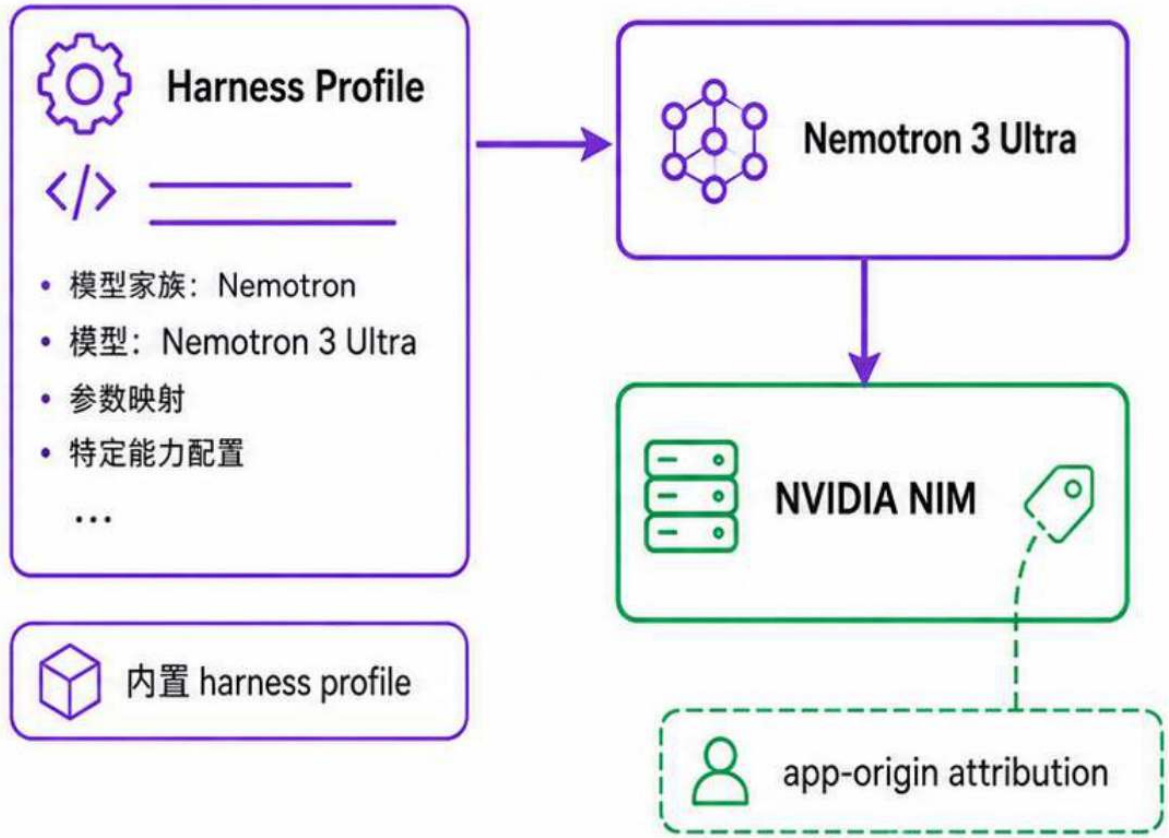
v0.7 还补齐了两类 Provider 能力

Prompt Caching 降低重复上下文成本，Harness Profile 适配特定模型

More Prompt Caching



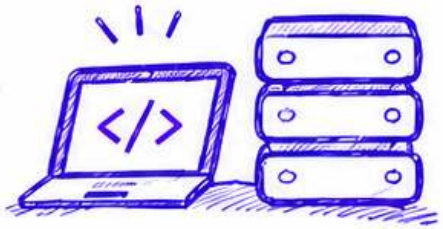
NVIDIA Support



Source: Deep Agents v0.7.0 changelog

升级阻塞项：兼容接口与输出约定

StoreBackend 没有移除；旧兼容写法需要迁移



	v0.6（旧）		v0.7（新）
1	✗ Backend factory callable	→	✓ 具体 BackendProtocol 实例
2	✗ 隐式 Store namespace / runtime=	→	✓ 显式 namespace；移除旧 runtime 参数
3	✗ BackendFactory / BACKEND_TYPES / FileFormat / Unset	→	✗ 移除旧符号
4	✗ ls_info / glob_info / grep_raw / 纯字符串 read()	→	✓ ls / glob / grep / ReadResult
5	✗ history_path_prefix	→	✓ 使用已配置 Backend 卸载历史
6	✗ FileData.content: list[str]	→	✓ 新数据用 string；旧 list[str] 仍可读取
7	✗ [] / Tab 行号解析 / success=完整	→	✓ No files found / 两空格 / 检查 truncated

FilesystemBackend / LocalShellBackend 默认 virtual_mode=True；namespace 必须验证租户隔离。

不要把面向模型的 ToolMessage 文本当稳定机器协议。

七步迁移，把升级变成可验证实验

日常锁定当前0.7.x；仅复现首发行为才固定0.7.0

⚠ 仅复现首发：deepagents==0.7.0

1 记录旧基线

任务、Trace、成功率、Token、成本

2 隔离升级

deepagents>=0.7,<0.8;

提交 lockfile

3 迁移 API

factory / namespace / 旧方法

4 声明策略

Todo / Prompt / Middleware / 权限

5 解析回归

空目录、Tab、分页、截断、覆盖、拒绝删除

6 同任务对照

轮次、工具、摘要、实际业务结果

7 渐进放量

关键验收通过，再扩大流量

⚠ 不要同时更换模型、提示词与业务工具；没有通用的90%覆盖率门槛，以关键场景验收为准。

是否恢复旧默认？先看应用依赖什么

不按怀旧程度决策，按任务、界面和风险边界决策。

应用特征	推荐行动	风险类别
短任务、无进度 UI	→ Todo 保持关闭	效率决策
长程任务或弱模型	→ Todo A/B 后显式启用	行为决策
解析原始文件输出	→ 输出迁移列为阻塞项	兼容性决策
暴露真实文件系统	→ 审查 delete、覆盖、权限与 HITL	安全决策
使用 StoreBackend	→ 显式 namespace 与租户隔离测试	行为决策

默认层保持轻量，策略由应用选择，结果由评测验证

